Trabajo Práctico 1 – Inferencia y Estimación

Profesores:

Copa, Debora

García Gulisano, Pau Ignacio

Ponce, Juan

Autores:

Lo Presti, Lautaro Emiliano

Etchegaray, Iñaki

Lopez Castro, Gonzalo

Universidad de San Andrés (UdeSA)

Año: 2026

1. Introducción

En este trabajo práctico se estudia el Análisis de Componentes Principales (PCA) aplicado a imágenes de células sanguíneas. La idea principal es ver cómo PCA permite reducir la cantidad de información necesaria para representar una imagen sin perder demasiada calidad. Cada imagen es de 28×28 píxeles, o sea que en principio tiene 784 valores, lo que resulta en vectores bastante grandes. El PCA busca encontrar las direcciones más importantes de variación en los datos para poder representarlos con menos componentes.

El objetivo del trabajo es básicamente dos cosas: primero, entender cómo afecta a la calidad de las imágenes el hecho de quedarnos con pocos componentes principales; y segundo, ver si usar PCA antes de clasificar mejora o empeora el resultado de un clasificador k-nn. Para eso usamos un dataset de cuatro tipos de células: eritroblasto, mieloblasto, monocito y plaqueta, con 500 imágenes por clase.

2. Ejercicio 1 — PCA por clase: varianza explicada y reconstrucción

2.1. Varianza explicada y MSE en función de K

Para este ejercicio aplicamos PCA de forma separada a cada clase. Básicamente calculamos la media y la matriz de covarianza de las 500 imágenes de cada clase, y a partir de ahí obtuvimos los autovectores y autovalores. Después, para cada valor de K probado (K = 1, 2, 3, 4, 5, 10, 20, 50, 100, 200, 500, 784), calculamos cuánta varianza total se explica con esos K componentes y cuál es el error cuadrático medio (MSE) al reconstruir las imágenes. Los resultados se ven en la Figura 1.

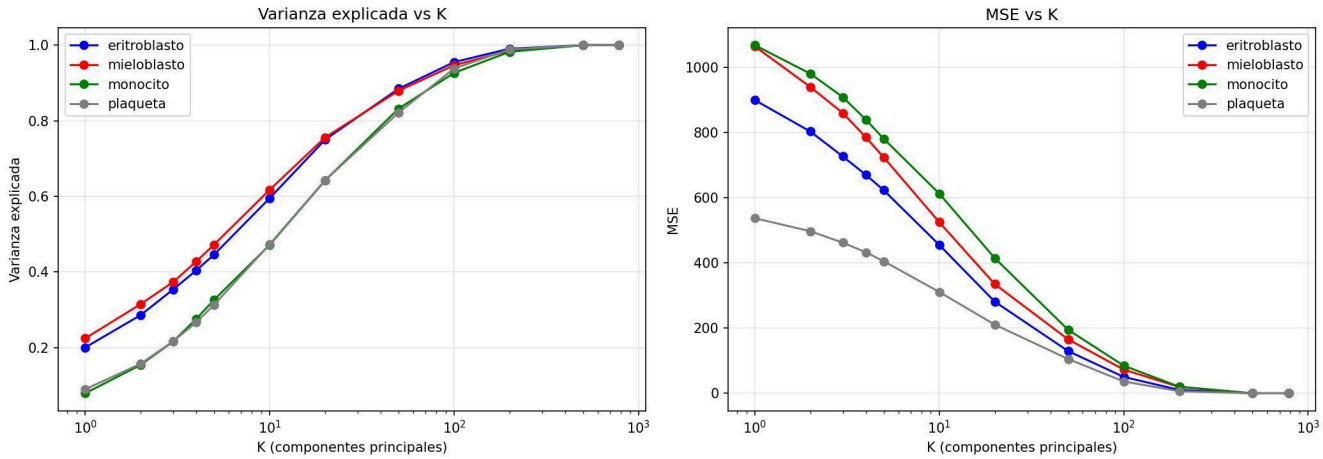

Figura 1. Izquierda: varianza explicada acumulada en función de K para las cuatro clases. Derecha: MSE de reconstrucción en función de K.

Lo primero que se nota es que todas las clases siguen un patrón parecido: la varianza explicada sube rápido al principio y después se va achicando la ganancia. Lo mismo pero al revés pasa con el MSE, que cae fuerte para K chico y después se estabiliza. Hay una diferencia interesante con la clase *plaqueta*: su curva de varianza sube más lento que las demás y tiene un MSE inicial bastante más bajo. Esto probablemente se debe a que las imágenes de plaquetas son más simples y uniformes que las otras, entonces hay menos variación entre ellas y su información está más concentrada en pocos componentes.

Las clases *eritroblasto* y *mieloblasto* tienen curvas muy parecidas entre sí. La clase *monocito* es la que arranca con el MSE más alto (alrededor de 1050), lo que indica que sus imágenes son las más variadas del dataset.

En general, con K=50 ya se recupera bastante bien la información de las imágenes, mientras que con K=2 la pérdida es muy grande. Tiene sentido porque a más varianza conservada, menos información se pierde y menor es el error de reconstrucción.

2.2. Reconstrucción visual de imágenes

Para ver esto de forma más concreta, tomamos una imagen de cada clase y la reconstruimos con K=50 y K=2. Los resultados se muestran en la Figura 2.

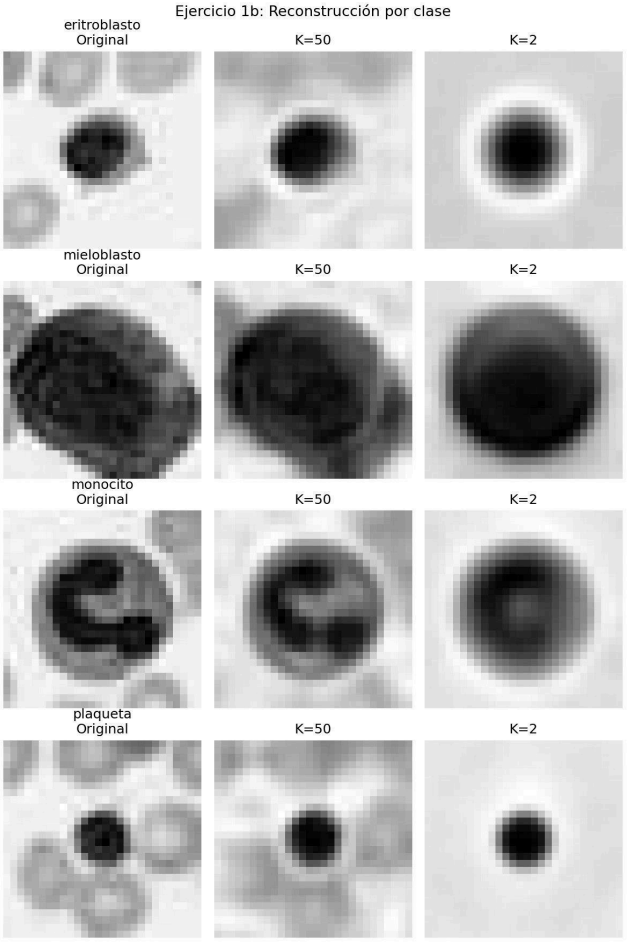

Figura 2. Reconstrucción de imágenes por clase. Columna izquierda: imagen original. Centro: reconstruida con K=50. Derecha: reconstruida con K=2.

Con K=50 la imagen reconstruida se parece bastante a la original. Se mantiene la forma de la célula, los bordes y parte de la textura. Las diferencias con el original son pequeñas y difíciles de notar a simple vista.

Con K=2 en cambio la imagen queda muy borrosa y sin detalles. Básicamente lo que se ve es la forma general y el brillo promedio, pero se pierde casi todo lo demás. Esto es consistente con las curvas del apartado anterior: con K=2 apenas se explica el 30% de la varianza aproximadamente, entonces es esperable que la reconstrucción sea tan mala. Lo que queda es como un promedio de todas las imágenes de esa clase con poca variación.

3. Ejercicio 2 — Clasificación k-nn con y sin PCA

En este ejercicio evaluamos qué tan bien clasifica un k-nn (con k=5 vecinos) usando los datos con y sin reducción de dimensionalidad. Juntamos las 2000 imágenes de las cuatro clases y las dividimos en 70% entrenamiento y 30% prueba, asegurándonos de que cada clase quede bien representada en ambas partes.

3.1. Clasificación sin reducción de dimensionalidad

Usando los vectores originales de 784 dimensiones, el clasificador obtuvo un accuracy de 0.8067 en el conjunto de prueba. Este es el valor de referencia contra el que comparamos el resto.

3.2. Clasificación con PCA para distintos valores de K

Acá se calculó PCA sobre todas las imágenes juntas y se proyectaron los datos sobre los K primeros componentes antes de pasarlos al clasificador. Se probaron los mismos valores de K que antes. Los resultados se ven en la Figura 3.

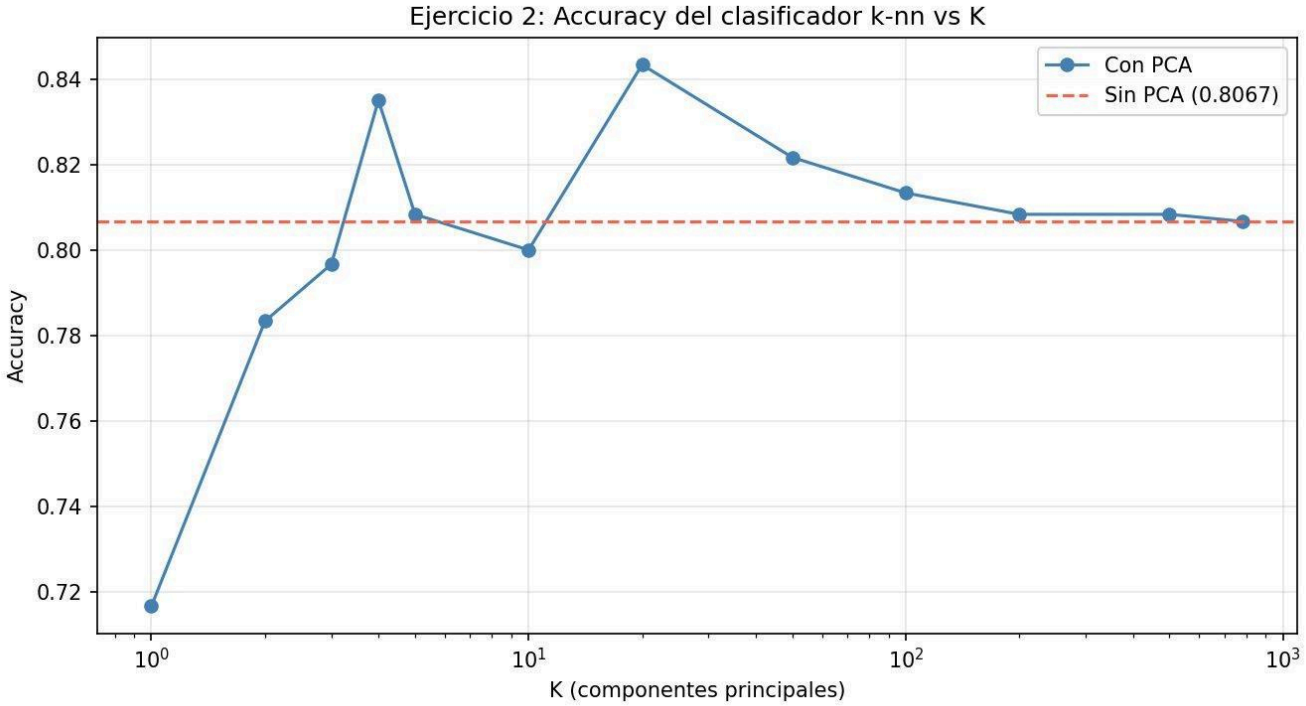

Figura 3. Accuracy del clasificador k-nn en función de K. La línea punteada roja es el accuracy sin PCA (0.8067).

Para K muy chico (K=1, K=2) el accuracy es bajo porque no hay suficiente información para distinguir bien las clases. A medida que K crece, el accuracy sube bastante rápido y supera el valor sin PCA ya desde K=5.

El mejor resultado se da en K=20, con un accuracy de 0.8433, lo que representa una mejora de casi 4 puntos respecto a usar los vectores completos. Vale aclarar que la curva no sube de forma completamente monótona: hay un pico en K=5 seguido de una leve caída en K=10 antes de volver a subir. Esto puede deberse a la variabilidad del muestreo aleatorio de las 500 imágenes por clase, dado que con K muy chico pequeñas diferencias en los datos tienen un impacto grande en el clasificador. Una posible explicación es que al quedarnos solo con los componentes más importantes estamos descartando ruido y variaciones poco relevantes que confunden al k-nn, que es bastante sensible a dimensiones que no aportan información. Para K más grande (entre 50 y 200) el accuracy sigue siendo mejor que sin PCA pero decrece gradualmente, y a partir de K≈500 converge al resultado sin reducción, lo cual tiene sentido porque con K=784 básicamente se usan todos los datos originales, simplemente rotados.

4. Ejercicio 3 — Visualización 2D por clase

Acá graficamos en 2D las 500 imágenes de cada clase, comparando dos formas distintas de representarlas. La Figura 4 muestra los dos casos.

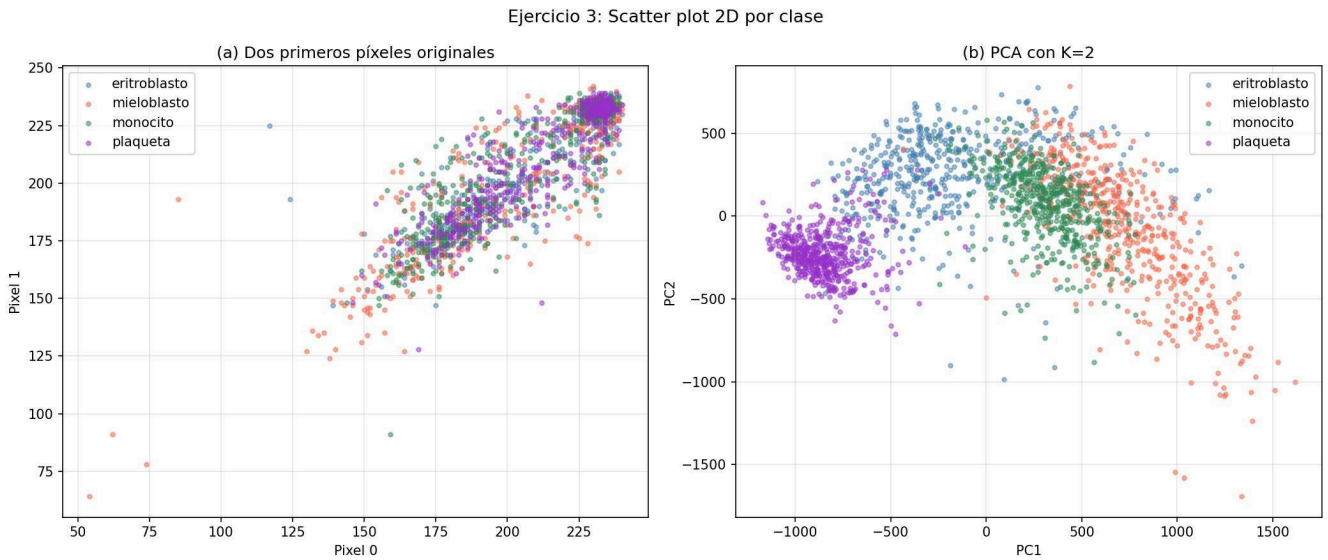

Figura 4. Scatter plot 2D de las cuatro clases. (a) Usando los dos primeros píxeles del vector original. (b) Usando las dos primeras componentes principales (K=2).

4.1. Dos primeros píxeles originales

Si usamos los primeros dos píxeles de cada imagen (esquina superior izquierda), los puntos de todas las clases se mezclan completamente. Todos los valores caen en una franja diagonal entre 150 y 240 de intensidad más o menos, sin que se puedan distinguir las clases. Esto pasa porque esos píxeles corresponden al fondo de la imagen, que es similar para todas las células, entonces no dicen nada útil sobre la clase a la que pertenece la imagen.

4.2. Primeras dos componentes principales

Con PCA la cosa cambia bastante. En el panel derecho se ve que las clases empiezan a separarse. La plaqueta es la que más se diferencia del resto: forma un grupo compacto bien separado hacia abajo en el eje PC2. Las otras tres clases se solapan más entre sí, pero igual tienen centroides distintos y se nota cierta separación.

Esto muestra bien lo que hace PCA: en vez de tomar dos coordenadas cualquiera, busca las direcciones en las que los datos varían más. En este caso esas direcciones capturan características de las imágenes que sí permiten distinguir las clases, como el tamaño, la forma o el brillo global de la célula. Eso explica por qué clasificar con K=2 en el espacio PCA da mejor resultado que usar dos píxeles aleatorios del vector original.

Cuantos más componentes agregamos, más información relevante incorporamos y mejor funciona el clasificador, como vimos en el ejercicio anterior.

5. Conclusiones

En este trabajo se vio cómo PCA puede usarse tanto para comprimir imágenes como para mejorar la clasificación. En el Ejercicio 1 quedó claro que con K=50 ya se recupera la mayor parte de la información visual de las imágenes, mientras que con K=2 la reconstrucción es muy pobre. Las

diferencias entre clases en las curvas reflejan que algunas tienen imágenes más homogéneas (plaqueta) y otras más variadas (monocito).

Para la clasificación, lo más llamativo fue que usar PCA como preprocesamiento puede mejorar el accuracy respecto a usar los vectores completos. El mejor resultado lo obtuvimos con K=20 (accuracy = 0.8433 vs 0.8067 sin PCA). La explicación más intuitiva es que PCA filtra el ruido y las dimensiones poco informativas que perjudican al k-nn.

La visualización 2D dejó en evidencia que las primeras dos componentes principales ya capturan información útil para separar las clases, algo que no pasa si usamos dos píxeles arbitrarios del vector original.

Una dificultad que encontramos fue decidir si calcular el PCA por clase o sobre todas las clases juntas para la parte de clasificación. Optamos por el PCA global porque nos pareció más consistente para una tarea multiclase, ya que así las componentes capturan diferencias entre clases y no solo variabilidad interna de cada una.

En conjunto, los tres ejercicios muestran una historia coherente: PCA no solo sirve para comprimir, sino que al eliminar dimensiones poco informativas mejora activamente la capacidad de un clasificador como k-nn, y la visualización 2D lo confirma de forma intuitiva.